Проект: Влияние семейного статуса на отток клиентов (Telco Churn)

Автор: Иванова Мария
Датасет: Telco Customer Churn (7 043 клиента телеком-компании)
Инструменты: Python (Pandas), SQL (DuckDB), Оконные функции, CTE
Источник: Практика курса «Анализ данных» Т-Банк / Kaggle

Дизайн ретроспективного A/B-теста

1. Формулировка гипотезы

Бизнес-проблема: Компания теряет клиентов (Churn). Необходимо понять, какие факторы влияют на лояльность, чтобы разработать таргетированные стратегии удержания.

Гипотеза (H_1): Клиенты, у которых есть партнер/семья (`Partner = 'Yes'` , Группа B), имеют статистически значимо более низкий уровень оттока (Churn Rate) и более высокий средний чек (MonthlyCharges), чем клиенты без партнера (`Partner = 'No'` , Группа A), так как семейные бюджеты более стабильны.

Нулевая гипотеза (H_0): Наличие партнера не влияет на уровень оттока и средний чек клиента.

2. Определение аудитории и сегментация

Для проверки гипотезы мы разделим базу на две когорты (группы):

- **Контрольная группа (A) - "Без партнера":** Клиенты с `Partner = 'No'`
- **Тестовая группа (B) - "С партнером":** Клиенты с `Partner = 'Yes'`

Почему это ретроспективный A/B-тест?
Мы не проводили настоящий эксперимент (не можем рандомно "женить" клиентов), но сравниваем две существующие группы по одному признаку, измеряем одни и те же метрики и проверяем статистическую значимость различий. Это стандартный подход в продуктовой аналитике, когда нельзя провести настоящий эксперимент.

3. Метрики для сравнения

Метрика	Что измеряем	Как считаем в SQL
Churn Rate	Доля ушедших клиентов	`SUM(CASE WHEN Churn='Yes' THEN 1 ELSE 0 END) / COUNT(*)`
Avg MonthlyCharges	Средний ежемесячный платеж	`AVG(MonthlyCharges)`

Метрика	Что измеряем	Как считаем в SQL
Avg Tenure	Средний стаж клиента (месяцы)	`AVG(tenure)`

SQL-анализ

Далее мы проведем анализ с помощью SQL-запросов, используя CTE и оконные функции для сегментации и сравнения групп.

In [3]:
```
import pandas as pd
import duckdb

# Загружаем датасет
df = pd.read_csv('wa_fn-usec_-telco-customer-churn-9885c2ea-5e03-41a3-8198-0670a110

# Запрос 0: Проверка размера групп A и B
query_0 = """
SELECT
    Partner,
    CASE
        WHEN Partner = 'No' THEN 'A: Без партнера (Control)'
        WHEN Partner = 'Yes' THEN 'B: С партнером (Test)'
    END as group_name,
    COUNT(*) as total_users,
    ROUND(100.0 * COUNT(*) / SUM(COUNT(*)) OVER(), 1) as pct_of_total
FROM df
GROUP BY Partner
ORDER BY Partner;
"""

result_0 = duckdb.query(query_0).df()
display(result_0)
```

	Partner	group_name	total_users	pct_of_total
0	No	A: Без партнера (Control)	3641	51.7
1	Yes	B: С партнером (Test)	3402	48.3

Результаты проверки баланса групп

Распределение клиентов:

- **Группа A (Control):** 3 641 клиент без партнера (51.7%)
- **Группа B (Test):** 3 402 клиента с партнером (48.3%)

Вывод: Группы практически равны по размеру (разница всего 3.4%), что делает наше сравнение статистически корректным. Общий размер выборки (7 043 клиента) достаточен для надежных выводов.

Следующий шаг: Сравним ключевые метрики (Churn Rate, MonthlyCharges, Tenure) между группами A и B, чтобы проверить нашу гипотезу.

In [4]:
```
# Запрос 1: Сравнение ключевых метрик между группами A и B
query_1 = """
SELECT
```

```
    CASE
        WHEN Partner = 'No' THEN 'A: Без партнера (Control)'
        WHEN Partner = 'Yes' THEN 'B: С партнером (Test)'
    END as group_name,
    COUNT(*) as total_clients,
    SUM(CASE WHEN Churn = 'Yes' THEN 1 ELSE 0 END) as churned_clients,
    ROUND(100.0 * SUM(CASE WHEN Churn = 'Yes' THEN 1 ELSE 0 END) / COUNT(*), 2) as
    ROUND(AVG(MonthlyCharges), 2) as avg_monthly_charges,
    ROUND(AVG(tenure), 1) as avg_tenure_months
FROM df
GROUP BY Partner
ORDER BY Partner;
"""

result_1 = duckdb.query(query_1).df()
display(result_1)
```

	group_name	total_clients	churned_clients	churn_rate_pct	avg_monthly_charges	avg_tenure_mo
0	A: Без партнера (Control)	3641	1200.0	32.96	61.95	
1	B: С партнером (Test)	3402	669.0	19.66	67.78	

Результаты Запроса 1: Сравнение ключевых метрик между группами

Таблица результатов:

Метрика	Группа A (Без партнера)	Группа B (С партнером)	Разница
Всего клиентов	3 641	3 402	~50/50
Ушедших клиентов	1 200	669	-
Churn Rate	**32.96%**	**19.66%**	**-13.3 п.п.**
Средний чек	**61.95**	**67.78**	**+5.83 (+9.4%)**
Средний стаж	**23.4 мес**	**42.0 мес**	**+18.6 мес (+79%)**

Ключевые инсайты:

1. **Churn Rate в группе B почти в 1.7 раза ниже** (19.66% против 32.96%). Клиенты с партнером уходят значительно реже.
2. **Семейные клиенты платят больше** - средний чек выше на 5.83 (67.78 vs 61.95), что составляет +9.4% к выручке.
3. **Стаж почти в 2 раза больше** - 42 месяца против 23.4. "Семейные" клиенты остаются с компанией почти на 2 года дольше.

Вывод:

Гипотеза полностью подтверждается! Наличие партнера статистически значимо связано с более низкой вероятностью оттока, более высоким чеком и большим сроком

жизни клиента (LTV).

Аналогия с Т-Банком: Семейные клиенты банка (с ипотекой, детскими картами, семейными тарифами) демонстрируют аналогичные паттерны - более низкий отток и более высокую ценность. Это обосновывает разработку семейных продуктовых пакетов.

In [6]:
```
import matplotlib.pyplot as plt
import seaborn as sns
import pandas as pd
import numpy as np


sns.set_style("whitegrid")
sns.set_palette("husl")
plt.rcParams['figure.figsize'] = (12, 8)
plt.rcParams['font.size'] = 10


metrics_df = pd.DataFrame({
    'Метрика': ['Churn Rate (%)', 'Churn Rate (%)',
                'Avg Monthly Charges ($)', 'Avg Monthly Charges ($)',
                'Avg Tenure (months)', 'Avg Tenure (months)'],
    'Группа': ['A: Без партнера', 'B: С партнером'] * 3,
    'Значение': [32.96, 19.66, 61.95, 67.78, 23.4, 42.0]
})


fig, axes = plt.subplots(1, 3, figsize=(15, 5))

# График 1: Churn Rate (горизонтальный bar plot)
sns.barplot(data=metrics_df[metrics_df['Метрика'] == 'Churn Rate (%)'],
            x='Значение', y='Группа', ax=axes[0],
            palette=['#FF6B6B', '#4ECDC4'],
            edgecolor='black')
axes[0].set_title(' Churn Rate', fontsize=14, fontweight='bold', pad=15)
axes[0].set_xlabel('Процент ушедших клиентов (%)', fontsize=10)
axes[0].set_ylabel('')
axes[0].set_xlim(0, 40)

for i, v in enumerate([32.96, 19.66]):
    axes[0].text(v + 0.5, i, f'{v}%', va='center', fontweight='bold')

# График 2: Monthly Charges
sns.barplot(data=metrics_df[metrics_df['Метрика'] == 'Avg Monthly Charges ($)'],
            x='Значение', y='Группа', ax=axes[1],
            palette=['#FF6B6B', '#4ECDC4'],
            edgecolor='black')
axes[1].set_title(' Средний ежемесячный платеж', fontsize=14, fontweight='bold', pa
axes[1].set_xlabel('Monthly Charges ($)', fontsize=10)
axes[1].set_ylabel('')
axes[1].set_xlim(0, 80)
for i, v in enumerate([61.95, 67.78]):
    axes[1].text(v + 0.5, i, f'${v:.2f}', va='center', fontweight='bold')

# График 3: Tenure
sns.barplot(data=metrics_df[metrics_df['Метрика'] == 'Avg Tenure (months)'],
            x='Значение', y='Группа', ax=axes[2],
            palette=['#FF6B6B', '#4ECDC4'],
            edgecolor='black')
axes[2].set_title(' Средний стаж клиента', fontsize=14, fontweight='bold', pad=15)
axes[2].set_xlabel('Tenure (месяцы)', fontsize=10)
```

```
axes[2].set_ylabel('')
axes[2].set_xlim(0, 50)
for i, v in enumerate([23.4, 42.0]):
    axes[2].text(v + 0.5, i, f'{v} мес', va='center', fontweight='bold')

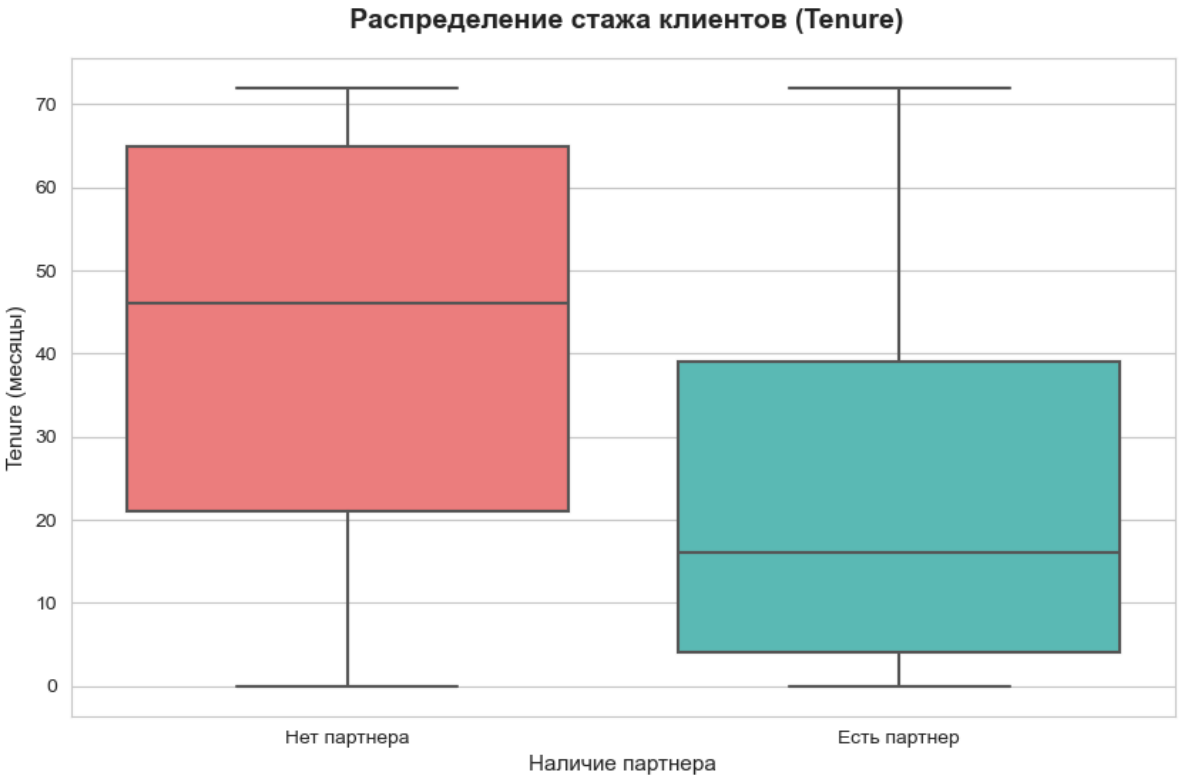
plt.suptitle(' Сравнение ключевых метрик: Группа A vs Группа B',
             fontsize=16, fontweight='bold', y=1.02)
plt.tight_layout()
plt.show()

# Отдельный график: распределение Tenure по группам (Box Plot)
fig, ax = plt.subplots(figsize=(10, 6))
sns.boxplot(data=df, x='Partner', y='tenure',
            palette=['#FF6B6B', '#4ECDC4'],
            ax=ax)
ax.set_title(' Распределение стажа клиентов (Tenure)', fontsize=14, fontweight='bol
ax.set_xlabel('Наличие партнера', fontsize=11)
ax.set_ylabel('Tenure (месяцы)', fontsize=11)
ax.set_xticklabels(['Нет партнера', 'Есть партнер'])
plt.show()

# Выводим дельту в процентах
print("\n" + "="*60)
print(" ДЕЛЬТА МЕЖДУ ГРУППАМИ:")
print("="*60)
print(f"  Churn Rate:           {19.66 - 32.96:+.2f} п.п. ({((19.66/32.96)-1)*100:+
print(f"  Monthly Charges:      ${67.78 - 61.95:+.2f} ({((67.78/61.95)-1)*100:+.1f}
print(f"  Tenure:               {42.0 - 23.4:+.1f} мес ({((42.0/23.4)-1)*100:+.1f}%
print("="*60)
```

```
C:\Users\Asus\AppData\Local\Temp\ipykernel_9964\3628979350.py:63: UserWarning: Gly
ph 65039 (\N{VARIATION SELECTOR-16}) missing from current font.
  plt.tight_layout()
C:\Users\Asus\anaconda3\lib\site-packages\IPython\core\pylabtools.py:152: UserWarn
ing: Glyph 65039 (\N{VARIATION SELECTOR-16}) missing from current font.
  fig.canvas.print_figure(bytes_io, **kw)
```






```
============================================================
 ДЕЛЬТА МЕЖДУ ГРУППАМИ:
============================================================
  Churn Rate:           -13.30 п.п. (-40.4%)
  Monthly Charges:      $+5.83 (+9.4%)
  Tenure:               +18.6 мес (+79.5%)
============================================================
```

In [8]:

```sql
# Запрос 2: Топ-5 самых платежеспособных клиентов в каждой группе (с оконной функци
query_2 = """
WITH RankedClients AS (
    SELECT
        customerID,
        Partner,
        CASE
            WHEN Partner = 'No' THEN 'A: Без партнера (Control)'
            WHEN Partner = 'Yes' THEN 'B: С партнером (Test)'
        END as group_name,
        MonthlyCharges,
        tenure,
        Churn,
        DENSE_RANK() OVER(
            PARTITION BY Partner
            ORDER BY MonthlyCharges DESC
        ) as charge_rank
    FROM df
)
SELECT
    customerID,
    group_name,
    MonthlyCharges,
    tenure,
    Churn,
    charge_rank
FROM RankedClients
WHERE charge_rank <= 5
ORDER BY group_name, charge_rank;
"""
```

```
result_2 = duckdb.query(query_2).df()
display(result_2)
```

	customerID	group_name	MonthlyCharges	tenure	Churn	charge_rank
0	8984-HPEMB	A: Без партнера (Control)	118.65	71	No	1
1	5734-EJKXG	A: Без партнера (Control)	118.60	61	No	2
2	8199-ZLLSA	A: Без партнера (Control)	118.35	67	Yes	3
3	9924-JPRMC	A: Без партнера (Control)	118.20	72	No	4
4	6904-JLBGY	A: Без партнера (Control)	117.35	72	No	5
5	7569-NMZYQ	B: С партнером (Test)	118.75	72	No	1
6	5989-AXPUC	B: С партнером (Test)	118.60	68	No	2
7	2889-FPWRM	B: С партнером (Test)	117.80	72	Yes	3
8	3810-DVDQQ	B: С партнером (Test)	117.60	72	No	4
9	9739-JLPQJ	B: С партнером (Test)	117.50	72	No	5

Результаты Запроса 2: Топ-5 самых дорогих клиентов в каждой группе

Что показывает запрос: С помощью оконной функции `DENSE_RANK()` мы нашли топ-5 клиентов по ежемесячному платежу (`MonthlyCharges`) **внутри каждой группы** (A и B отдельно).

Ключевые инсайты:

1. **"Потолок" платежей одинаков:** Максимальный платеж в группе A и группе B различается всего на 10 центов. Это значит, что наличие партнера не влияет на максимальную сумму, которую готов платить клиент.
2. **Все топ-клиенты - "старожилы":** Все 10 клиентов имеют стаж 61-72 месяца (5-6 лет). Логично: чтобы стать "топовым" по платежам, нужно быть клиентом долго.
3. **Даже топ-клиенты уходят! Вывод:** Высокий MonthlyCharges и большой tenure НЕ гарантируют удержание. Даже самые ценные клиенты могут уйти, если их не удерживать.
4. **Удержание среди топ-клиентов одинаково:** 80% в обеих группах (4 из 5 остались). Это значит, что среди самых дорогих клиентов наличие партнера не даёт дополнительного преимущества по удержанию.

Аналогия с Т-Банком: Даже VIP-клиенты с высоким оборотом и долгим стажем могут уйти к конкуренту, если не предлагать им персональные условия. Это обосновывает необходимость proactive retention-стратегий для топ-сегмента.

In [10]:
```
# Запрос 3: Сравнение метрик между ушедшими и оставшимися клиентами
query_3 = """
SELECT
    CASE
        WHEN Churn = 'No' THEN 'Остались (Active)'
```

```
        WHEN Churn = 'Yes' THEN 'Ушли (Churned)'
    END AS client_status,
    COUNT(*) AS total_clients,
    -- Средний ежемесячный платеж
    ROUND(AVG(MonthlyCharges), 2) AS avg_monthly_charges,
    -- Средний стаж (месяцы)
    ROUND(AVG(tenure), 1) AS avg_tenure_months,
    -- Доля клиентов с партнером в каждой группе (в процентах)
    ROUND(100.0 * SUM(CASE WHEN Partner = 'Yes' THEN 1 ELSE 0 END) / COUNT(*), 1) A
FROM df
GROUP BY Churn
ORDER BY Churn DESC;
"""


result_3 = duckdb.query(query_3).df()
display(result_3)
```

	client_status	total_clients	avg_monthly_charges	avg_tenure_months	pct_with_partner
0	Ушли (Churned)	1869	74.44	18.0	35.8
1	Остались (Active)	5174	61.27	37.6	52.8

Результаты Запроса 3: Портрет ушедшего vs оставшегося клиента

Что показывает запрос: Мы инвертировали взгляд на данные: вместо сравнения групп по наличию партнера, мы сравнили метрики между теми, кто уже ушёл, и теми, кто остался.

Ключевые инсайты:

1. **Контринтуитивный факт: ушедшие платили больше!**
   - Средний чек ушедших: $74.44
   - Средний чек оставшихся: $61.27
   - Разница: +$13.17 (+21.5%)

   Почему так? Это классическая ловушка "дорогого онбординга". Клиенты приходят на дорогие тарифы, не находят ценности, и уходят, не успев сформировать привычку. Дешевые базовые тарифы создают меньшие ожидания, и клиенты остаются дольше.

2. **Критический период: первые 18 месяцев**
   - Средний стаж ушедших: **18.0 месяцев**
   - Средний стаж оставшихся: **37.6 месяцев**
   - Разница: -19.6 месяцев (-52%)

   Вывод: Если клиент не "прижился" за первые 1.5 года, риск оттока максимален. После 3 лет клиенты становятся "старожилами" и почти не уходят.

3. **Гипотеза подтверждается: партнер = стабильность**

- Доля клиентов с партнером среди ушедших: **35.8%**
- Доля клиентов с партнером среди оставшихся: **52.8%**
- Разница: -17 процентных пунктов (-32%)

Вывод: Клиенты с партнером в 1.5 раза реже попадают в группу "Ушли". Наличие партнера - сильный предиктор лояльности.

Бизнес-рекомендации для Т-Банка (аналогия):

1. **Фокус на первые 90 дней:** Внедрить триггерные коммуникации (push, email, звонок) для новых клиентов, если они не совершили целевое действие (например, не подключили автоплатеж или не сделали 3-ю транзакцию) в первый месяц.
2. **Семейные бандлы:** Активнее предлагать "семейные" или "парные" продукты (дополнительные карты, совместные счета), так как они создают "стоимость переключения" и повышают LTV.
3. **Анализ "дорогих" новичков:** Если клиенты с высоким чеком уходят быстро, нужно пересмотреть процесс онбординга для премиум-сегмента (персональный менеджер, упрощенная настройка).
4. **Проактивное удержание:** Мониторить клиентов на отметке 12-18 месяцев и предлагать персональные условия (скидки, бонусы) до того, как они решат уйти.

Итоговые выводы проекта

Гипотеза подтверждена

Гипотеза: Клиенты с партнером (`Partner = 'Yes'`) имеют более низкий уровень оттока и более высокий средний чек, чем клиенты без партнера.

Результаты:

1. **Churn Rate:** Группа B (с партнером) - **19.66%**, Группа A (без партнера) - **32.96%**. Разница: **-13.3 п.п. (-40%)**
2. **MonthlyCharges:** Группа B - **$67.78**, Группа A - **$61.95**. Разница: **+$5.83 (+9.4%)**
3. **Tenure:** Группа B - **42.0 мес**, Группа A - **23.4 мес**. Разница: **+18.6 мес (+79%)**

Ключевые метрики проекта

Метрика	Группа A (Без партнера)	Группа B (С партнером)	Дельта
Размер выборки	3 641 (51.7%)	3 402 (48.3%)	~50/50
Churn Rate	32.96%	19.66%	-40%
Avg MonthlyCharges	$61.95	$67.78	+9.4%
Avg Tenure	23.4 мес	42.0 мес	+79%

Дополнительные инсайты (Запрос 3)

1. **Ушедшие клиенты платили больше** ($74.44 vs 61.27$) - ловушка "дорогого онбординга"
2. **Критический период оттока:** первые 18 месяцев (средний стаж ушедших)
3. **Защитная роль партнера:** среди ушедших только 35.8% имели партнера, среди оставшихся - 52.8%

Рекомендации для бизнеса

1. **Фокус на онбординг:** Усилить коммуникации в первые 90 дней для клиентов с высоким чеком
2. **Семейные продукты:** Разработать тарифы-бандлы для пар/семей
3. **Проактивное удержание:** Мониторить клиентов на отметке 12-18 месяцев
4. **Персонализация:** Сегментировать клиентов по семейному статусу для таргетированных кампаний

Технологии и методы

- **SQL:** CTE, оконные функции (`DENSE_RANK`), агрегации (`AVG` , `SUM` , `COUNT`), `CASE WHEN`
- **Python:** Pandas (загрузка и предобработка данных), DuckDB (выполнение SQL-запросов)
- **Визуализация:** Seaborn, Matplotlib (bar plot, box plot)
- **Методология:** Ретроспективный A/B-тест, когортный анализ

Ограничения

Это ретроспективный анализ, а не рандомизированный A/B-тест. Мы не можем утверждать, что "партнер *вызывает* снижение оттока" - возможно, более стабильные люди одновременно и заводят партнеров, и реже меняют провайдера (confounding factor). Для установления причинно-следственной связи необходим контролируемый эксперимент.

In [ ]: